

Projeto T2M

Cliente: T2M - Gestor de recursos humanos e diretoria estratégica

Projeto: SABIÁ - Sistema de Análises Baseadas em Integração de Aptidões

Equipe: Davi, Isabel, Nathália e Pedro

Tema: Gestão de projetos Hard Skills

Objetivo: Avaliar as competências técnicas (hard e soft skills) dos colaboradores e sua alocação em projetos, com foco em aprimorar a gestão e a performance organizacional.

Justificativa: A empresa detectou uma carência de indicadores mensuráveis de aptidões e competências de seu quadro de colaboradores. Essa lacuna dificulta a alocação estratégica de profissionais com as habilidades mais adequadas para cada projeto e a identificação de áreas que necessitam de desenvolvimento.

Solução: Sistema analítico para apoiar decisões na T2M, integrando um banco PostgreSQL no Docker com uma pipeline ETL e dashboards em Power BI. Permite visualizar dados gerais, informações de colaboradores e gaps de competências, potencializando o capital intelectual da empresa.

Fluxo de trabalho dentro da estrutura medalhão:




Figura 1: Arquitetura do sistema analítico de apoio à decisão da T2M. A camada Bronze representa as fontes de dados brutas (PostgreSQL e Excel). Na camada Prata, os dados foram armazenados e processados via pipeline ETL em Python dentro do Docker, transformando-os em dados tratados. A camada Ouro corresponde à camada de

visualização e consulta, onde os dados tratados foram explorados através de dashboards no Power BI e consultas SQL.

Arquitetura da Base de Dados:

Inicialmente um banco de dados relacional PostgreSQL foi criado contendo 09 tabelas brutas, diretamente carregadas sem tratamento prévio (**Figura 2**). Paralelamente, foram disponibilizados 05 arquivos **.csv** externos que não integravam inicialmente o banco.




Figura 2: Diagrama ilustrando o relacionamento inicial entre tabelas no banco de dados PostgreSQL.

Descrição dos dados originais:

a. Tabelas brutas que compõem o banco de dados.

Nome original	Fonte	Colunas	Descrição
colaborador_202508051406.csv	PostgreSQL	6	Tabela com dados pessoais dos colaboradores
colaborador_competencia_202508051407.csv	PostgreSQL	3	Tabela de ligação entre colaborador e competências
colaborador_empresa_202508051408.csv	PostgreSQL	3	Tabela de ligação entre colaborador e empresa
colaborador_photo_202508051408.csv	PostgreSQL	3	Tabela com foto de cada colaborador
competencia_202508051408.csv	PostgreSQL	3	Tabela com competências técnicas e respectivas descrições
empresa_202508051409.csv	PostgreSQL	6	Tabela com dados gerais de contato e localização da empresas

empresa_servico_202508051409.csv	PostgreSQL	2	Tabela de ligação entre empresas e serviço
servico_202508051409.csv	PostgreSQL	4	Tabela com serviços e respectivas descrições
servico_competencia_202508051409.csv	PostgreSQL	2	Tabela de ligação entre serviço e competência
dados_colaboradores 1(DadosCertificações).csv	Fonte externa	7	Tabela com certificações e datas das certificações de cada colaborador
dados_colaboradores 1(DadosPCD).csv	Fonte externa	2	Tabela com situação PCD dos colaboradores
dados_colaboradores 1(DadosPrimarios).csv	Fonte externa	11	Tabela com dados pessoais, de localização e qualificação profissional dos colaboradores
dados_colaboradores 1(DataAdmissao).csv	Fonte externa	2	Tabela com data de admissão dos colaboradores
dados_colaboradores 1(Softskills).csv	Fonte externa	6	Tabela com as soft skills dos colaboradores

b. Tipo das variáveis e problemas encontrados.

Tabela: colaborador_202508051406.csv

Nome da Coluna	Tipo de variável	Observações/Problemas encontrados
id_colaborador	varchar (255) not null	-
nome_colaborador	text	Alguns nomes iniciados com pronome de tratamento
email_colaborador	text	Formatos inconsistentes com email, sem @ e .com; células vazias; Alguns e-mails com domínios ausentes; nomes antes do '@' que não correspondem ao nome do colaborador, indicando possível uso indevido.
cpf	varchar (20)	CPFs sem pontuação padrão, com formato incorreto com números repetidos ou incompletos
data_nascimento	text	Datas sem formatação e não padronizadas
telefone	text	Combina telefone e estado em um único campo; Há números com e sem formatação, códigos de país (+55) apenas em alguns números. Alguns DDDs começam com 0, e há casos em que o DDD não corresponde ao estado informado.

Tabela: colaborador_competencia_202508051407.csv

Nome da Coluna	Tipo de variável	Observações/Problemas encontrados
id	bigint	ID (PK) que não aparece em nenhuma outra tabela
id_colaborador	varchar (255)	-
id_competencia	bigint	-

Tabela: colaborador_empresa_202508051408.csv

Nome da Coluna	Tipo de variável	Observações/Problemas encontrados
----------------	------------------	-----------------------------------

id	bigint not null	40 IDs (40 colaboradores não estão vinculados à empresas parceiras)
id_colaborador	varchar (255)	-
id_empresa	bigint	-

Tabela:colaborador_photo_202508051408.csv

Nome da Coluna	Tipo de variável	Observações/Problemas encontrados
id	bigint not null	-
id_colaborador	varchar (255)	-
url_foto	text	Células vazias; Há muitos campos nulos o que indica que alguns colaboradores não possuem foto

Tabela:competencia_202508051408.csv

Nome da Coluna	Tipo de variável	Observações/Problemas encontrados
id_competencia	bigint not null	-
descricao	text	id_competencia 10 não é uma hard skill mas sim uma soft skill
nome_competencia	text	Nível da competência junto com o nome; alguns sem nível ; id_competencia 10 não é uma hard skill mas sim duas soft skills juntas

Tabela: empresa_202508051409.csv

Nome da Coluna	Tipo de variável	Observações/Problemas encontrados
id_empresa	bigint not null	-
cnpj_empresa	varchar (20)	CNPJs sem pontuação padrão ou com dígitos incompletos
contato_empresa	text	Há números com e sem formatação, códigos de país (+55) apenas em alguns números. Alguns DDDs começam com 0, e há casos em que o DDD não corresponde ao estado informado.
endereco_empresa	text	Logradouro, número e estado na mesma coluna
nome_empresa	text	“Empresa” no início de alguns nomes
setor_empresa	text	Setor sem padrão, alguns nomes com letras maiúsculas e outras minúsculas

Tabela: empresa_servico_202508051409.csv

Nome da Coluna	Tipo de variável	Observações/Problemas encontrados
empresa_id	bigint	-
servico_id	bigint	-

Tabela: servico_202508051409.csv

Nome da Coluna	Tipo de variável	Observações/Problemas encontrados
id_servico	bigint not null	-

data_servico	text	Datas sem formatação e não padronizadas. Data do id_servico 4 sendo 30 de Fevereiro, ou seja, não existente
descricao_servico	text	Id_servico 4 possui uma descrição que não faz sentido (serviço inválido)
nome_servico	text	Variável que resume a descrição do serviço sem padronização

Tabela: servico_competencia_202508051409.csv

Nome da Coluna	Tipo de variável	Observações/Problemas encontrados
servico_id	bigint	servico_id 3,7 e 8 vinculados à competencia_id 10, que não é uma competência e sim duas soft skills juntas
competencia_id	bigint	competencia_id 10 não é uma competência e sim duas soft skills juntas

Tabela: dados_colaboradores 1(DadosCertificações).csv

Nome da Coluna	Tipo de variável	Observações/Problemas encontrados
ID	int64	-
Certificação	object	células vazias / certificações repetidas (inglês/português)
data	object	não está no formato datetime
Certificação	object	células vazias / certificações repetidas (inglês/português)
data.1	object	não está no formato datetime
Certificação	object	células vazias / certificações repetidas (inglês/português)
data.2	object	não está no formato datetime

Obs: Power BI, Azure Data e Admin Expert - dois nomes para a mesma certificação. Manter apenas um.

Tabela: dados_colaboradores 1(DadosPCD).csv

Nome da Coluna	Tipo de variável	Observações/Problemas encontrados
ID	int64	-
Situação PCD	object	Sem formato padrão para “sim” e “não”

Tabela: dados_colaboradores 1(DadosPrimarios).csv

Nome da Coluna	Tipo de variável	Observações/Problemas encontrados
ID	int64	-
Nome	object	Alguns nomes iniciados com pronomes de tratamento
Email	object	Formatos inconsistentes com email, sem @ e .com; células vazias; Alguns e-mails com domínios ausentes; nomes antes do '@' que não correspondem ao nome do colaborador, indicando possível uso indevido.
CPF	object	CPFs sem pontuação padrão, com formato incorreto e com números repetidos

Data de Nascimento	object	Datas sem formatação e não padronizadas
Telefone	object	Há números com e sem formatação, códigos de país (+55) apenas em alguns números. Alguns DDDs começam com 0, e há casos em que o DDD não corresponde ao estado informado.
Estado	object	-
Cidade	object	-
Endereço	object	Dados de logradouro, número e Estado na mesma coluna
Formação Acadêmica	object	-
Treinamentos Realizados	object	-

Tabela:dados_colaboradores 1(DataAdmissao).csv

Nome da Coluna	Tipo de variável	Observações/Problemas encontrados
Data	object	não está no formato datetime / 2 datas anteriores à criação da T2M (ID 1 e 2)
Id	int64	-

Tabela:dados_colaboradores 1(Softskills).csv

Nome da Coluna	Tipo de variável	Observações/Problemas encontrados
ID	int64	-
Soft Skill 1	object	-
Soft Skill 2	object	células vazias
Soft Skill 3	object	células vazias
Soft Skill 4	object	células vazias
Soft Skill 5	object	células vazias

Relacionamento das tabelas originais:

- Existem muitos relacionamentos muito para muitos
- Os relacionamentos estão configurados em muitos para um

Relacionamento	Tipo	Tabelas envolvidas
Colaborador - Competência	Muitos para muitos	colaborador_competencia
Colaborador - Empresa	Muitos para muitos	colaborador_empresa
Empresa - Serviço	Muitos para muitos	empresa_servico
Serviço - Competência	Muitos para muitos	servico_competencia

Colaborador - Foto	Um para um	colaborador_photo
--------------------	------------	-------------------

Metodologia:

a. Criação de ambiente virtual via Docker (Docker Compose):

Um ambiente virtualizado utilizando Docker Compose foi desenvolvido, sendo composto por dois serviços principais: um banco de dados PostgreSQL e um pipeline ETL. O banco de dados utiliza a imagem **postgres:13**, com persistência em volume e execução de scripts de inicialização automática.

O pipeline ETL foi implementado em container próprio, com dependência direta do banco de dados. Ele executa automaticamente o script **run-etl.sh**, responsável pela extração, transformação e carga dos dados entre os schemas de origem e destino definidos nas variáveis de ambiente. Além disso, ele acessa os arquivos .csv externos, realiza integrações e mantém a automação do fluxo de dados. Esse setup garante reprodutibilidade, integração entre desenvolvimento e produção, além de automatizar o processo de ETL em um ambiente simulado de produção.

b. Tratamento e transformações gerais:

Os dados brutos foram importados do schema “*ProjetoDados25.1*”, apresentando erros, duplicidades e inconsistências que precisaram ser tratados. O pipeline ETL foi implementado em Python, rodando dentro do container. As bibliotecas necessárias para execução estão listadas no arquivo de requisitos do container (*requirements.txt*) e incluem: ‘*pandas*’ e *numpy* (manipulação de dados), ‘*sqlalchemy*’ e ‘*psycopg2-binary*’ (conexão com PostgreSQL), ‘*papermill*’ e ‘*jupyter*’ (automatização e execução de notebooks), e ‘*geopy*’ (cálculos geoespaciais e geocodificação).

Isso permitiu a extração e manipulação dos dados diretamente no ambiente de análise. Os dados passaram por diversas etapas de limpeza:

- Padronização de datas (datetime) e categorias
- Unificação e renomeação de colunas
- Remoção de espaços e caracteres especiais
- Reordenamento de colunas em linhas
- Criação de tabelas fato e dimensão para ajustar os relacionamentos “muitos para muitos” e “muitos para um” em “um para muitos”
- Geração de arquivos tratados com o sufixo “-tratado.csv”

- Os dados tratados foram armazenados em um novo schema “*projetoDados2025_v2*”.

c. Tratamentos específicos para cada tabela:

- i. **Tratamento_Dados_Primaryos.ipynb:** Limpeza, padronização e validação dos dados de colaboradores, incluindo CPF (xxx.xxx.xxx-xx), telefones, nomes, datas de nascimento, e-mails (xxx@xxx.com), formação acadêmica e treinamentos realizados. Colunas irrelevantes/redundantes foram removidas, e dados foram transformados para formatos consistentes. Treinamentos e formação foram deslocados para tabelas dimensionais separadas.
- ii. **Tratamento_DataAdmissao.ipynb:** Limpeza e conversão da coluna de datas para datetime.
- iii. **Tratamento_PCD.ipynb:** Padronização (sim/não) da coluna de PCD, renomeação da coluna e adição de um ID único.
- iv. **Tratamento_Certificacoes.ipynb:** Renomeação e organização das colunas, transformação dos dados de múltiplas certificações em uma tabela única, limpeza e conversão das datas, tradução dos nomes de certificações para português.
- v. **Tratamento_Softskills.ipynb:** Transformação de várias colunas de habilidades em uma tabela única e remoção dos valores ausentes.
- vi. **Tratamento_competencia.ipynb:** Identificação e padronização dos níveis (Básico, Intermediário, Avançado) a partir do nome e da descrição da competência, limpeza da descrição para evitar redundância, renomeação das colunas e filtragem de registros indesejados.
- vii. **Tratamento_servicos.ipynb:** Conversão de diferentes formatos para datetime, renomeação e padronização dos nomes de serviços e colunas.
- viii. **Tratamento_Email.ipynb:** Leitura dos dados primários, correção e padronização dos emails adicionando domínio quando necessário.

- ix. **coordenadas.ipynb:** Criação de uma tabela única de cidades com IDs e coordenadas geográficas usando a API do Nominatim a partir das cidades contidas na tabela de dados primários. Associação dos colaboradores ao ID da cidade, ajuste dos endereços, remoção das colunas redundantes.
- x. **Tratamento_relacao_colaborador_empresa.ipynb:** Junção das tabelas para associar cada colaborador a uma empresa, preenchendo valores ausentes com um ID padrão, padronização dos tipos de dados e nomes de colunas.
- xi. **Tratamento_empresa.ipynb:** Adição da empresa T2M para poder relacionar os colaboradores internos , padronização de nomes, setores e endereços, validação e formatação dos telefones e CNPJs, criação de colunas auxiliares de logradouro, número e estado e renomeação das colunas.
- xii. **Tratamento_relacao_colaborador_certificacao.ipynb:** Conversão das datas e tipos de ID, e criação de tabelas de dimensão e fato, gerando uma dimensão de certificações e uma tabela de ligação (fato) com os colaboradores.
- xiii. **Tratamento_relacao_colaborador_formacao.ipynb:** Renomeação de colunas para padronização e criação de tabelas dimensão e fato, gerando uma dimensão de formações e uma tabela de ligação (fato) associando colaboradores às suas formações acadêmicas.
- xiv. **Tratamento_relacao_colaborador_softskills.ipynb:** Renomeação de coluna para padronização e criação de tabelas de dimensão e fato, gerando uma dimensão de soft skills e uma tabela de ligação (fato) associando colaboradores às suas habilidades.
- xv. **Tratamento_relacao_colaborador_treinamento.ipynb:** Renomeação de coluna para padronização e criação de tabelas de dimensão e fato, gerando uma dimensão de treinamentos e uma tabela de ligação (fato) associando colaboradores aos treinamentos que realizaram.
- xvi. **Tratamento_relacao_colaborador_competencia.ipynb:** Padronização dos nomes das colunas e identificação dos colaboradores com a competência 10

(que é uma soft skill e não uma competência). Para esses colaboradores, criou-se novas relações com as soft skills específicas (IDs 3 e 19), atualizando a tabela fato de soft skills existente. Em seguida, remoção da competência 10 da tabela original, garantindo que não haja duplicidade. O script salva tanto a tabela fato de soft skills atualizada quanto a tabela de competências filtrada.


- xvii. **Tratamento_relacao_dataAdmissao_colaborador.ipynb:** Criação de uma tabela de dimensão de datas de admissão. Carrega os arquivos tratados de dados primários e datas de admissão, renomeação e padronização das colunas, e conversão da coluna de data para formato datetime. Geração da tabela dimensão com IDs únicos para cada data, merge com a tabela de admissão e depois integração da chave à tabela de dados primários.
- xviii. **Tratamento_relacao_colaborador_photo.ipynb:** Padronização das colunas, preenchimento de fotos ausentes com um link padrão contendo uma foto genérica de “foto a ser atualizada” ("<https://i.imgur.com/dZT0p3i.jpeg>").
- xix. **Tratamento_relacao_empresa_servico.ipynb:** Importação da tabela de relacionamento entre empresas e serviços, com renomeação das colunas para padronização.
- xx. **Tratamento_relacao_servico_competencia.ipynb:** Importação da tabela de relacionamento entre serviços e competências, com renomeação das colunas para padronização, remoção da competência específica (Id 10).
- xxi. **insert_db.ipynb:** Construção do modelo relacional no banco de dados (schema *projetoDados2025_v2*), envolvendo criação de tabelas de dimensão e fato, padronização de colunas, aplicação de filtros (como exclusão de competências específicas), e uso de chaves primárias e estrangeiras para garantir integridade referencial, que resultou em uma estrutura organizada que permite análises consistentes e integração com outras ferramentas.

Todos os datasets tratados foram exportados como .csv com os caminhos de armazenamento configurados via variáveis de ambiente, prontos para análises e integrações futuras. Mais detalhes sobre os scripts podem ser verificados nos notebooks disponibilizados dentro do repositório

'Dados_2025_1_T2M_Projeto-Sabia_Backend'


(https://github.com/serratec/Dados_2025_1_T2M_Projeto-Sabia_Backend.git)

d. Banco de dados tratado com as novas dimensões e relações:



e. Exportação e Integração com Power BI:

Após o tratamento, os dados foram importados no Power BI. A modelagem relacional foi validada no ambiente do Power BI, assegurando consistência entre as conexões das tabelas, aplicação correta de filtros e funcionamento adequado das segmentações.



Relacionamento no PowerBi após conexão. Arquivo disponível no repositório Dados_2025_1_T2M_Projeto-Sabia_FrontEnd
(https://github.com/serratec/Dados_2025_1_T2M_Projeto-Sabia_FrontEnd.git)

f. Validação:

Todos os filtros, segmentações e relacionamentos foram testados para garantir consistência lógica entre os dados e os dashboards.

g. Criação das medidas DAX:

Algumas medidas DAX foram criadas para facilitar a visualização dos dados no dashboard, mantendo os relacionamentos funcionando.

Dashboard (pág. 2) - Colaboradores

Nome_Colaborador

- **Descrição:** Exibe o nome do colaborador selecionado.
- **Tabelas utilizadas:** colaborador.
- **Retorno:** Nome ou "-".
- **Uso:** Card

Cidade_Colaborador

- **Descrição:** Recupera a cidade do colaborador
- **Tabelas utilizadas:** colaborador, cidade.
- **Retorno:** Nome da cidade ou "-".
- **Uso:** Card

Email_Colaborador

- **Descrição:** Retorna o e-mail do colaborador selecionado.
- **Tabelas utilizadas:** colaborador.
- **Retorno:** E-mail ou "-".
- **Uso:** Card

Telefone_Colaborador

- **Descrição:** Exibe o telefone do colaborador.
- **Tabelas utilizadas:** colaborador.

- **Retorno:** Número de telefone ou "-".
- **Uso:** Card

Empresa_Colaborador

- **Descrição:** Identifica a empresa em que o colaborador atua.
- **Tabelas utilizadas:** colaborador, empresa, colaborador_empresa.
- **Retorno:** Nome da empresa ou "-".
- **Uso:** Card

Tempo_Vinculo_Colaborador

- **Descrição:** Calcula o tempo de vínculo do colaborador desde sua admissão até a data atual, retornando em anos e meses.
- **Tabelas utilizadas:** colaborador, data_admissao.
- **Retorno:** Texto (ex.: "X anos e X meses") ou "-".
- **Uso:** Card

DataAdmissao_Colaborador

- **Descrição:** Recupera a data de admissão do colaborador.
- **Tabelas utilizadas:** colaborador, data_admissao.
- **Retorno:** Data de admissão ou "-".
- **Uso:** Card

Competencias_Colaborador

- **Descrição:** Lista todas as competências associadas ao colaborador selecionado.
- **Tabelas utilizadas:** colaborador, colaborador_competencia, competencia.
- **Retorno:** Texto concatenado com competências.
- **Uso:** Tabela

Formacao_Colaborador

- **Descrição:** Lista todas as formações acadêmicas de um colaborador.
- **Tabelas utilizadas:** colaborador, colaborador_formacao, formacao_academica.
- **Retorno:** Texto concatenado com formações. Caso não tenha, retorna "Não tem".
- **Uso:** Tabela

TreinamentoXCompetencia_Filtros

- **Descrição:** Multiplica a quantidade de treinamentos distintos realizados por colaboradores pelo número de competências distintas, respeitando filtros de empresa e competência.
- **Tabelas utilizadas:** colaborador_treinamentos, colaborador_competencia, empresa, competencia.
- **Retorno:** Número inteiro.
- **Uso:** Tabela

Certificacao_Colaborador

- **Descrição:** Lista todas as certificações vinculadas a um colaborador selecionado.
- **Tabelas utilizadas:** colaborador, colaborador_certificacao, certificacao.
- **Retorno:** Texto com certificações separadas por vírgula. Caso não tenha certificação, retorna "-".
- **Uso:** Tabela

SoftSkills_Colaborador

- **Descrição:** Lista as soft skills associadas ao colaborador selecionado.
- **Tabelas utilizadas:** colaborador, colaborador_softskills, softskills.
- **Retorno:** Texto concatenado com as soft skills.
- **Uso:** Tabela

Dashboard (pág. 3) - Regiões: Soft x Hard skills

Colab_com_Certificacao

- **Descrição:** Conta colaboradores com pelo menos uma certificação registrada.
- **Tabelas utilizadas:** colaborador, colaborador_certificacao.
- **Retorno:** Número de colaboradores ou `"-".
- **Uso:** Card

Pct_Colab_com_Certificacao

- **Descrição:** Percentual de colaboradores que possuem ao menos uma certificação.

- **Tabelas utilizadas:** colaborador, colaborador_certificacao.
- **Retorno:** Percentual formatado (%) ou "-".
- **Uso:** Card

h. Ferramentas utilizadas:

- Postgres
- Docker
- VSCode
- DBeaver
- Python
- Power BI
- GitHub

i. Análise dos Dados

A análise de dados foi realizada no Power BI, por meio de exploração gráfica e criação de dashboard interativo. O objetivo principal foi visualizar e compreender os dados de forma intuitiva, permitindo identificar distribuições e comparações entre variáveis. Foram utilizados gráficos de barras, colunas, rosca, mapas e segmentações dinâmicas para facilitar a interpretação das informações. Essa etapa não envolveu análises estatísticas complexas, mas possibilitou um entendimento inicial do conjunto de dados e levantou pontos relevantes para discussões posteriores.

Paralelamente, desenvolvemos uma análise de clusterização aplicada ao conjunto de dados de colaboradores, competências, treinamentos, soft skills, empresas e serviços. As tabelas tratadas foram importadas a partir de arquivos .csv e organizadas em dimensões (colaboradores, empresas, competências, treinamentos, serviços, soft skills) e fatos (relacionamentos entre colaboradores, empresas, serviços e competências). Para a análise, foram removidas colunas irrelevantes e criadas versões simplificadas de cada tabela.

Com base nisso, foram geradas matrizes binárias de presença/ausência para: Hard Skills (competências técnicas), Soft Skills (competências comportamentais) e treinamentos realizados. Essas matrizes permitiram calcular estatísticas básicas (totais por colaborador) e servir de base para os modelos de clusterização. Para identificar perfis semelhantes de colaboradores, foi aplicada a

técnica de K-Means sobre as matrizes de hard skills, soft skills e treinamentos. Antes da clusterização, os dados foram padronizados e reduzidos por PCA (Análise de Componentes Principais) para possibilitar visualização em duas dimensões.

Os clusters foram representados em: (i) Gráficos de dispersão (PCA) mostrando a separação dos grupos; (ii) Heatmaps exibindo a distribuição média das competências/treinamentos por cluster; (iii) Gráficos de barras empilhadas comparando a composição dos clusters entre empresas.

Além da clusterização, foram realizadas análises de correlação: (i) Correlação entre Hard Skills e Soft Skills totais por colaborador; (ii) Heatmaps de correlação individual entre competências técnicas e comportamentais; (iii) Teste de significância (p-values) para avaliar a força das relações. Também foi avaliada a aderência de colaboradores aos serviços das empresas, verificando o percentual de profissionais aptos a cada serviço com base nas competências exigidas. Essa análise foi representada por um heatmap no dashboard.

Mais detalhes sobre o script de análise pode ser verificado no notebook disponibilizado dentro do repositório '*Dados_2025_1_T2M_Projeto-Sabia_Backend*' (https://github.com/serratec/Dados_2025_1_T2M_Projeto-Sabia_Backend.git)

j. Resultados

Análises exploratórias:

- A maioria dos colaboradores prestam serviços no setor de TI (n=64). O setor de Análise de dados, em contraposição, possui apenas 4 colaboradores alocados em uma única empresa.
- O total de colaboradores PCD é baixo comparado com o total, representando apenas 7,5% do total de colaboradores.
- SQL, C#, Python e React são as competências mais frequentes entre os colaboradores
- Todos os colaboradores possuem, pelo menos, 1 treinamento. O curso de Power BI é o que tem um menor número de colaboradores.
- Interessantemente um gap é observado no setor de Análise de Dados, onde nenhum dos 4 colaboradores diz ter competência em SQL e Análise de Dados, além de apenas 2 colaboradores terem treinamento em excel avançado e só 1 ter em Power BI.

- O estado com o maior número de colaboradores é o RJ, distribuídos nas cidades de Niterói, Rio de Janeiro e Nova Iguaçu.
- Dos 80 colaboradores, apenas 33 possuem certificações técnicas, representando 41,3% do total. Isso indica um gap no número de funcionários certificados.
- Além disso, os colaboradores, em sua maioria, não declararam o nível (básico, intermediário e avançado) das suas competências. A região sudeste apresenta uma distribuição mais igualitária em relação a essa métrica, com colaboradores em todos os níveis. Já no RN e SC, os colaboradores possuem apenas skills nível básico.

Clusterização e correlação:

De modo geral, os clusters refletiram hard skills, soft skills e treinamentos de forma coerente. Para as **competências técnicas** (Figura 4), o Cluster 0 tendeu a perfis analíticos e orientados a dados (forte em Análise de Dados e SQL, com alguma presença em C#). O Cluster 1 representou um perfil mais generalista, com destaque para React, Metodologias Ágeis e Gestão de Projetos, o que indica um foco em desenvolvimento ágil e gestão. O Cluster 2 teve presença significativa de Python e C#, com um pouco de Metodologias Ágeis, indicando perfil de desenvolvedores/programadores. O Cluster 3 é forte em Arquitetura de Software, indicando provavelmente um perfil de profissionais mais sêniores.




Figura 4: Distribuição de Hard Skills por Cluster. O mapa de calor evidencia a concentração de competências técnicas em cada cluster.

Na distribuição de **soft skills por cluster** (Figura 5), o Cluster 0 foi mais forte em Foco em Resultados, Proatividade e Trabalho Interdisciplinar, indicando um perfil mais prático e integrado. O Cluster 1 concentrou características de Curiosidade, Colaboração, Comunicação e Resolução de Problemas, representando um perfil comunicativo e criativo. O Cluster 2 destacou-se pelas habilidades Atenção aos Detalhes, Negociação, Resolução de Problemas e Visão Sistêmica, indicando um perfil mais analítico enquanto o Cluster 3 mostrou-se mais associado à criatividade e ética profissional, representando um perfil com valores fortes. Essa diversidade evidencia que os clusters não se restringem a aspectos técnicos, mas também refletem perfis comportamentais distintos, fundamentais para a composição de equipes multidisciplinares.




Figura 5: Distribuição de Soft Skills por Cluster. O mapa de calor apresenta a predominância de competências comportamentais em cada cluster.

Os resultados dos clusters de treinamento (Figura 6) mostraram que o Cluster 0 tem maior foco em Power BI e Segurança da Informação. O Cluster 1 concentra colaboradores ligados ao desenvolvimento web, com destaque em React e também em Segurança da Informação. Já o Cluster 2 apresenta perfil associado à gestão e processos, evidenciado pelos treinamentos em Excel Avançado e Scrum.

Por fim, o Cluster 3 reúne profissionais mais diversos, que buscaram múltiplas capacitações, com ênfase em Power BI, React, Excel e Scrum.






Figura 6: Distribuição de Treinamentos por Cluster. O mapa de calor demonstra quais capacitações foram mais frequentes em cada cluster.

Por fim, ao analisar a distribuição dos clusters por empresa (Figura 7), observou-se que a Empresa 11 (T2M) é a que concentra a maior parte dos colaboradores, abrangendo todos os perfis identificados e evidenciando elevada heterogeneidade em sua força de trabalho. As demais empresas parceiras, por outro lado, apresentaram uma distribuição mais homogênea e restrita em termos de clusters, com menor diversidade de perfis técnicos e comportamentais. Esse resultado reforça o papel da T2M como eixo central da diversidade de competências, tanto técnicas quanto comportamentais, além de maior investimento em treinamentos.

(A)



(B)



(C)




Figura 7: Distribuição de clusters de (A) Hard Skills; (B) Soft Skills; (C) Treinamentos por Empresa. O gráfico de barras empilhadas apresenta a quantidade de colaboradores de cada cluster por empresa. Empresas: 1 = Alfa; 2 = Beta; 3 = Gama; 4 = Tech Soluções; 5 = Inova Sistemas; 6 = Data Insights; 7 = Global Soft; 8 = NextGen Tech; 9 = RS Sistemas; 10 = SC Tecnologia; 11 = T2M.

Os resultados obtidos mostraram uma correlação positiva moderada entre Resolução de Problemas e Metodologias Ágeis (0,45), indicando que os colaboradores que tem essa soft skill também costumam ter metodologias ágeis. A proatividade também esteve correlacionada com a Gestão de projetos (0,32), indicando que os colaboradores proativos têm tendência a desenvolver gestão de projetos. A Resiliência esteve positivamente relacionada com SQL (0,34), mostrando que persistência pode estar ligada a domínio técnico em SQL. Por fim, a Ética profissional esteve positivamente correlacionada com Arquitetura de Software (0,27), apontando uma pequena relação entre postura ética e competências de arquitetura. No entanto, algumas correlações negativas chamam atenção como Criatividade e Gestão de Projetos (-0,22), sugerindo que foco em processos de gestão pode estar inversamente ligado à criatividade. Além disso, colaboração e Python (-0,17) também tiveram leve tendência negativa, talvez por perfil mais individual do aprendizado técnico.




Figura 8: Heatmap das correlações entre Soft Skills e Hard Skills dos colaboradores. A matriz de correlação cruzada mostra o grau de associação entre diferentes competências técnicas (Hard Skills) e comportamentais (Soft Skills), permitindo identificar relações positivas (vermelhas) e negativas (azuis) relevantes para a análise de perfis profissionais.

O percentual de colaboradores aptos por serviço em cada empresa evidencia que a distribuição de aptidão é desigual entre os colaboradores. Alguns serviços, como o **6**, têm maior cobertura de pessoal capacitado, enquanto outros ficam descobertos. Isso pode indicar a necessidade de **treinamentos direcionados** e realocação de funcionários para equilibrar a força de trabalho. Os valores mais altos aparecem em **Serviço 6**, especialmente nas **empresas 2, 5 e 8**, todas com **16%**, indicando que esse serviço concentra a maior proporção de colaboradores aptos. Já os valores mais baixos (**3%**) aparecem nos **Serviços 7 e 8**, em algumas empresas, sugerindo carência de colaboradores aptos nesses casos. Empresas como a **8** têm especialização mais concentrada (forte no serviço 6, mas baixa no 7).




Figura 9: Heatmap do percentual de colaboradores aptos por serviço em cada empresa. A intensidade da cor indica a proporção de colaboradores capacitados em cada combinação empresa–serviço, permitindo identificar padrões de distribuição de competências entre as organizações. Empresas: 1 = Alfa; 2 = Beta; 3 = Gama; 4 = Tech Soluções; 5 = Inova Sistemas; 6 = Data Insights; 7 = Global Soft; 8 = NextGen Tech; 9 = RS Sistemas; 10 = SC Tecnologia; 11 = T2M. Serviços: 1 = Manutenção; 2

= Atualização; 3 = Implantação; 4 = Serviço Errado; 5 = Auditoria; 6 = Desenvolvimento; 7 = Treinamento; 8 = Consultoria.

k. Conclusão

- A maioria dos colaboradores está concentrada em TI; áreas como Análise de Dados apresentam baixa representatividade e lacunas técnicas.
- Apenas 41% dos colaboradores possuem certificações técnicas; PCDs representam 7,5% do total dos colaboradores.
- Perfis técnicos e comportamentais são diversos, evidenciando potencial para equipes multidisciplinares.
- Correlações entre soft e hard skills indicam alinhamentos naturais entre competências.
- Distribuição de aptidões por serviços e empresas é desigual, com alguns serviços e empresas concentrando a maior parte dos colaboradores capacitados.

Aplicações práticas:

- Treinamentos direcionados: Priorizar capacitação em SQL, Power BI e Excel Avançado, especialmente em setores com lacunas identificadas (Análise de Dados, Serviços 7 e 8).
- Certificações estratégicas: Incentivar certificações técnicas para aumentar a credibilidade e nível de especialização da equipe.
- Alocação de talentos: Formar equipes multidisciplinares considerando clusters técnicos e comportamentais.
- Realocação de colaboradores: Redistribuir pessoal para equilibrar cobertura de aptidões entre serviços e empresas parceiras.
- Gestão de diversidade: Fortalecer políticas de inclusão (PCDs) e desenvolvimento de competências em regiões com skills limitados.

I. Referências

DockerDocs. Disponível em <https://docs.docker.com/compose/>. Acesso em: 18 de agosto de 2025.

scikit-learn: KMeans clustering. Disponível em:
<https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html>.
Acesso: 21 de agosto de 2025.

Introduction to k-Means Clustering with scikit-learn in Python. Disponível em:
<https://www.datacamp.com/tutorial/k-means-clustering-python>. Acesso: 21 de agosto de 2025.

In Depth: k-Means Clustering. Disponível em:
<https://jakevdp.github.io/PythonDataScienceHandbook/05.11-k-means.html>. Acesso: 21 de agosto de 2025.

Comparison of Methods to Inform K-Means Clustering. Disponível em:
<https://towardsdatascience.com/comparison-of-methods-to-inform-k-means-clustering-a830cdc8db50/>. Acesso: 21 de agosto de 2025.